Time Series Forecasting для KPI бизнес-процессов через Transformer

Финальный проект - ЦОС

Ageev Daniel Alikhanovich

Прогноз weekly cycle time и case arrivals на event-logs `142_БЗ` (внутренний) и `BPI Challenge 2017` (публичный)

1. Постановка задачи

Контекст: организации записывают журналы событий бизнес-процессов (банк, налоговая, страховая). Из них извлекаются операционные KPI: случаи в неделю, средний цикл выполнения и т.д.

Задача: прогнозировать недельные KPI на 8 недель вперёд через **обученную нейронную сеть** (encoder-only Transformer).

Зачем:

- planning ресурсов (количество исполнителей)
- SLA-мониторинг (когда время выйдет за порог)
- обнаружение аномалий

Что сравниваем:

- 5 classical/lag-based baselines
- наш Transformer (обучен с нуля)
- Chronos zero-shot (pretrained foundation model)

2. Обзор подходов в литературе

семейство	примеры	сильны на
Classical	ARIMA, exp.smoothing, MA	коротких регулярных рядах
Lag-ML	Ridge / XGBoost on lags	structured tabular data
Sequence NN	LSTM, Transformer	длинных рядах с context
Foundation TS	TimesFM, Chronos, Moirai	zero-shot на гладких KPI

Ключевые работы:

- De Smedt et al. 2023 - Process Model Forecasting
- Lim et al. 2024, ICML - **TimesFM**: decoder-only foundation TS
- Ansari et al. 2024 - **Chronos**: pretrained для time series
- Vaswani et al. 2017 - архитектура Transformer

Тезис из обзора: на коротких рядах (50-100 точек) простые модели часто конкурентны. На длинных - выигрывает Transformer / foundation.

3. Данные и EDA

name	events	cases	период	weekly длина
`142_БЗ`	67 K	5 426	2021 - 2024	99 точек
`bpi2017`	1.2 M	31 509	2016 - 2017	53 точки

Train / test split: последние 8 недель → test, остальные → train.

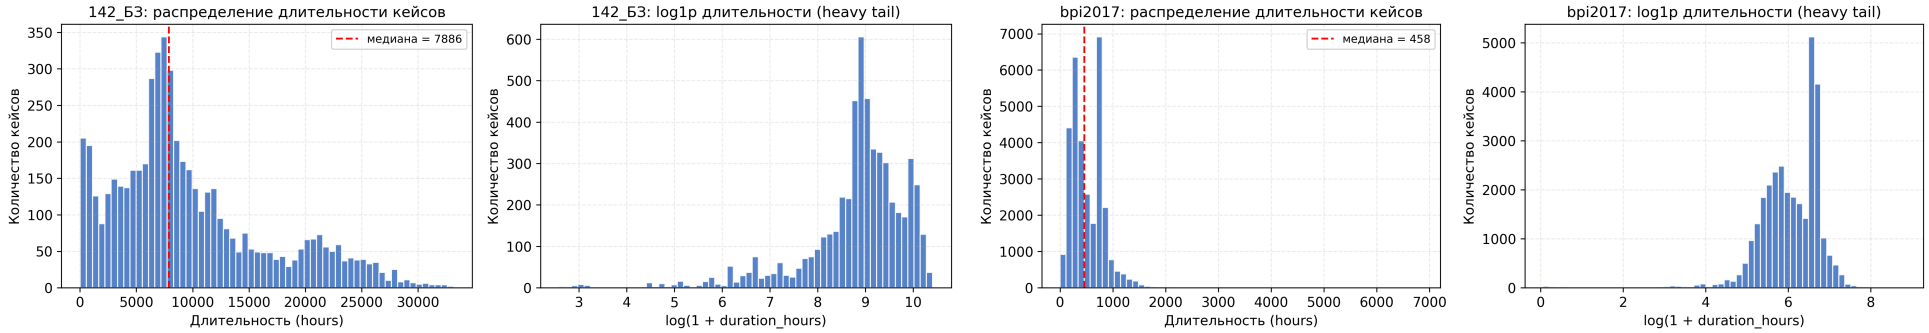

Распределение длительности кейсов: тяжёлый правый хвост, log1p почти симметризует.

3. Данные и EDA - weekly KPI

bpi2017 (53 точки):

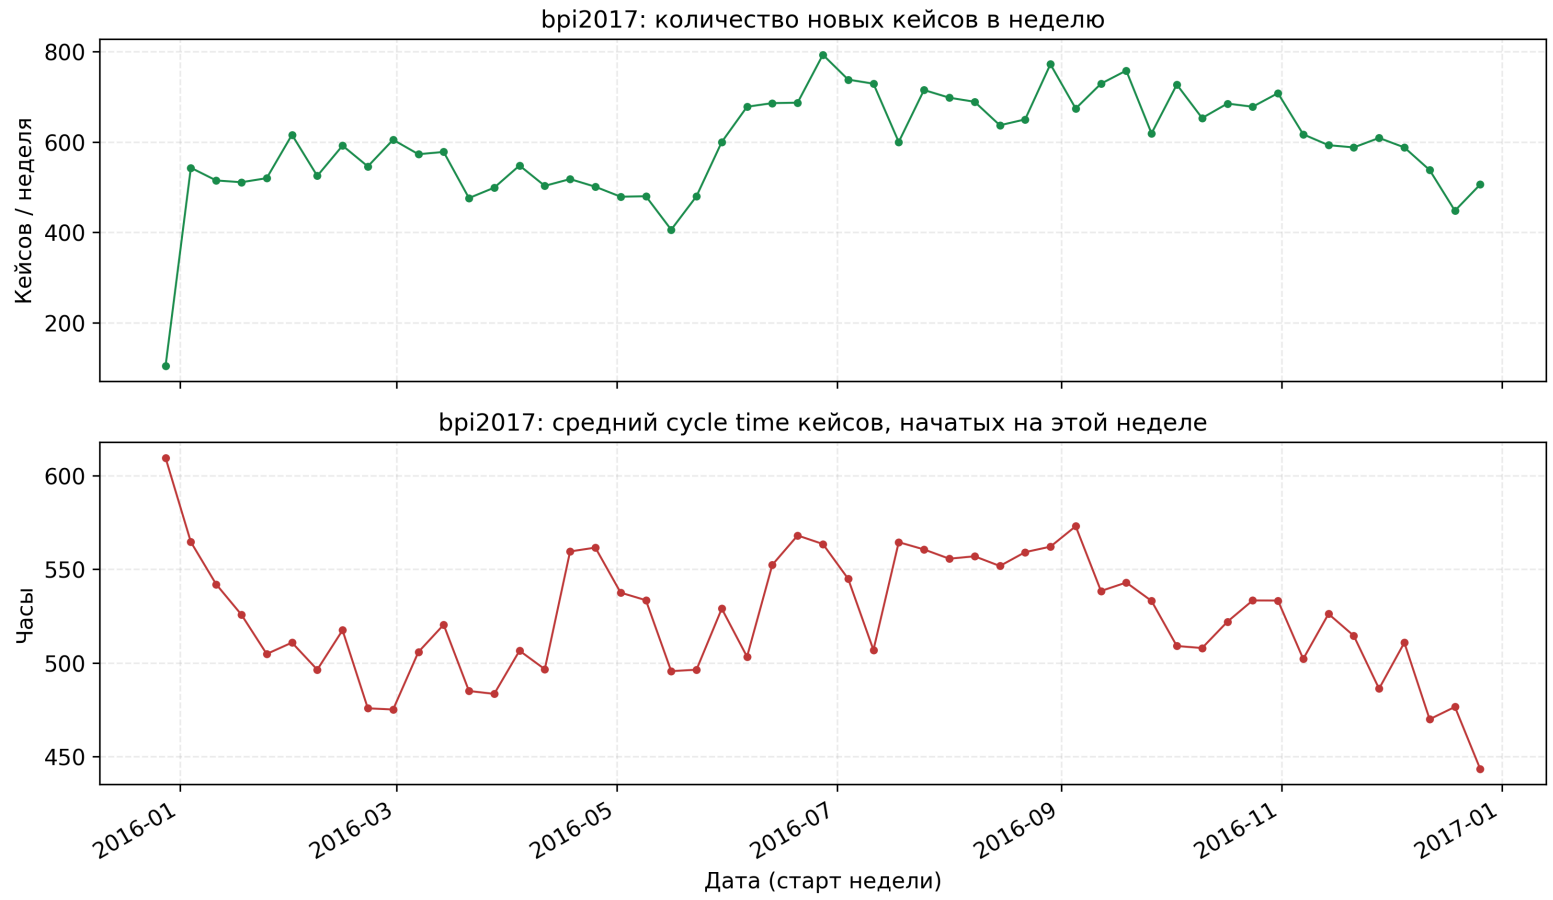

142_БЗ (99 точек): exponential trend на arrivals, drift на cycle_time

3. Данные и EDA - train/test split

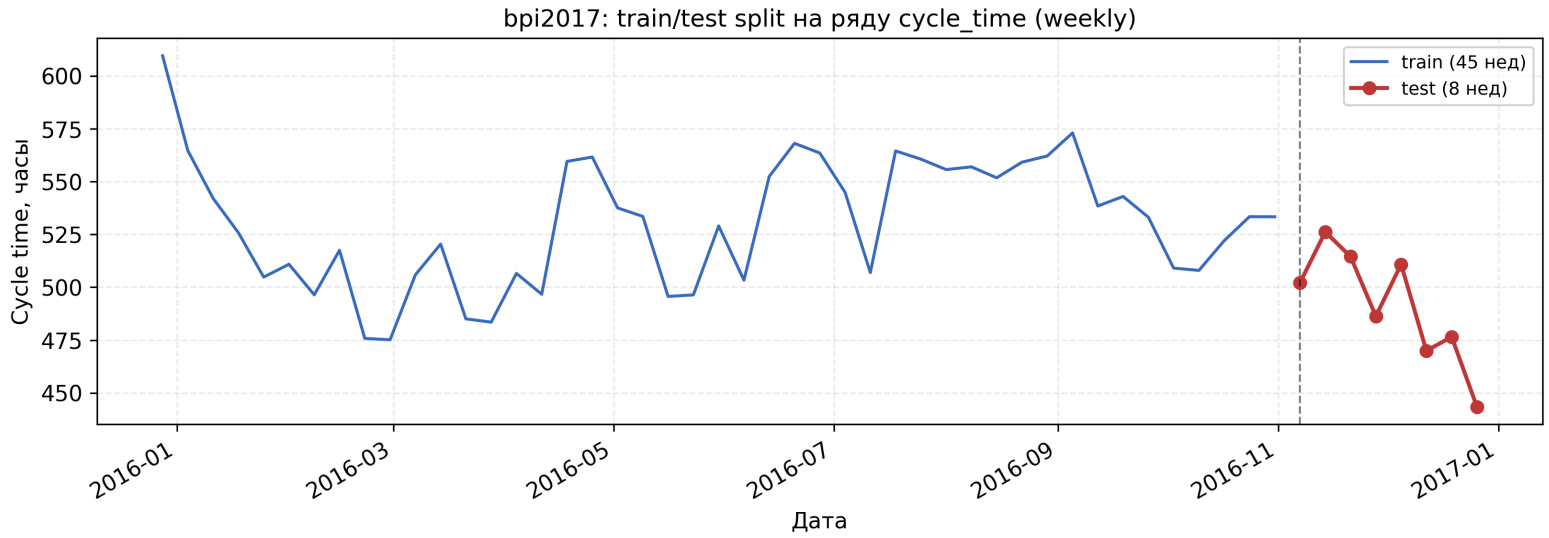

Train последние 24 недели контекста + test 8 недель.

Видна слабая нисходящая тенденция в конце 2016 → test 2017.

4. Метод: encoder-only Transformer

```
input:  [batch, context_len=24]   - стандартизованные delta_y
        |
        v
Linear(1 → 64)  +  Learnable Positional Embedding(24, 64)
        |
        v
TransformerEncoderLayer × 2:
   - MultiHeadAttention(nhead=4, dropout=0.1)
   - FFN(64 → 128 → 64), GELU, dropout
        |
        v
Mean Pool по time-axis  →  [batch, 64]
        |
        v
MLP head: Linear(64 → 64) → GELU → Dropout → Linear(64 → 1)
        |
        v
output: предсказание delta_y_{t+1}
```

Trainable params: 72 833 - компактная модель для коротких рядов

4. Метод - почему работает

Ключевые решения:

1. **Обучаем delta_y, не y** - стационарность для рядов с трендом
2. **Стандартизация только по train** - нет утечки
3. **Mean pooling** - стабильнее CLS-token на коротком ряде
4. **SmoothL1 loss** - robust к выбросам в heavy-tail распределении
5. **AdamW + grad clip + dropout 0.1 + weight_decay** - регуляризация
6. **Восстановление прогноза**: $y_pred = y_\{t-1\} + (delta_pred \cdot \sigma + \mu)$

Тренировка: 80 эпох, batch=32, lr=1e-3 на CPU - **1.5 секунды**

5. Логи обучения

Train loss SmoothL1 монотонно падает: **0.34** → **0.10** за 80 эпох.

Никакого катастрофического overfit (нет резкого роста train_loss), ранний стоп не понадобился.

6. Проблемы и их решения

проблема	решение
Короткие ряды (53 точки → 21 train window)	малая модель (72k params), delta-обучение, регуляризация
Heavy tail на 142_БЗ	SmoothL1 loss + параллельный MedianAE как метрика
Концепт-дрифт на 142_БЗ	явно показано через time-based vs case-based split
Конфликт OpenMP на macOS	`KMP_DUPLICATE_LIB_OK=TRUE`
Foundation Chronos слабее на коротком ряду	не ошибка - честный результат, согласуется с Yu 2026
TimesFM требует Python 3.10+	заменено на Chronos, который работает на 3.9

7. Результаты: bpi2017 cycle_time (53 точки)

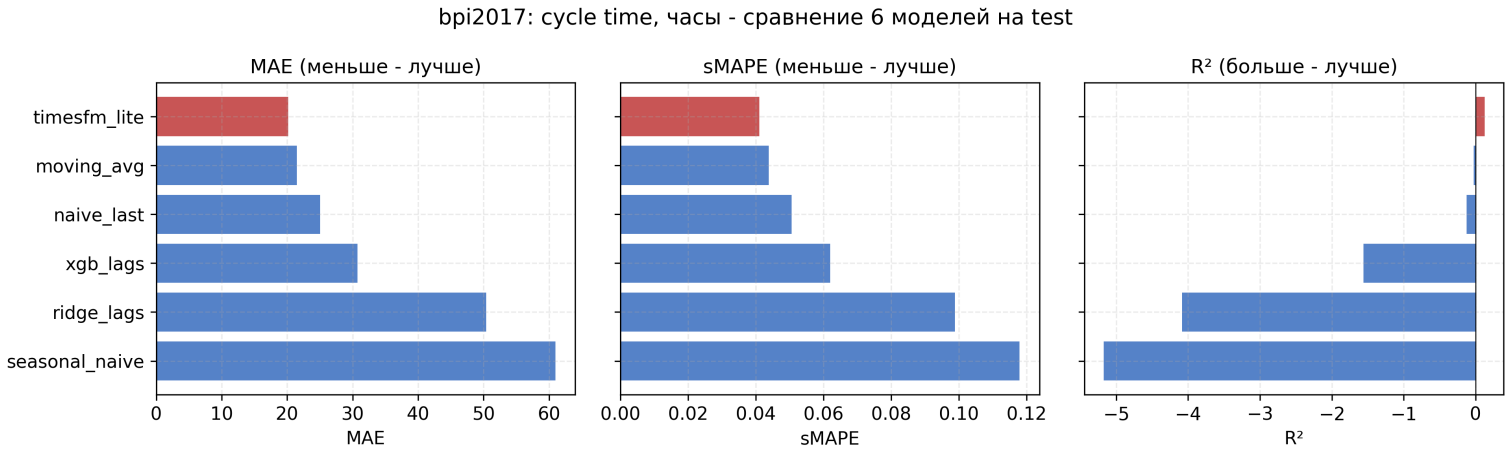

модель	MAE (ч)	sMAPE	R^2
naive_last	25.04	0.051	-0.125
moving_avg	21.49	0.044	-0.027
Transformer (наш)	**20.16**	**0.041**	**+0.126**
chronos zero-shot	27.86	0.057	-0.631

Наш Transformer - лидер по всем трём метрикам, единственный с $R^2 > 0$

7. Результаты: predicted vs actual (bpi2017)

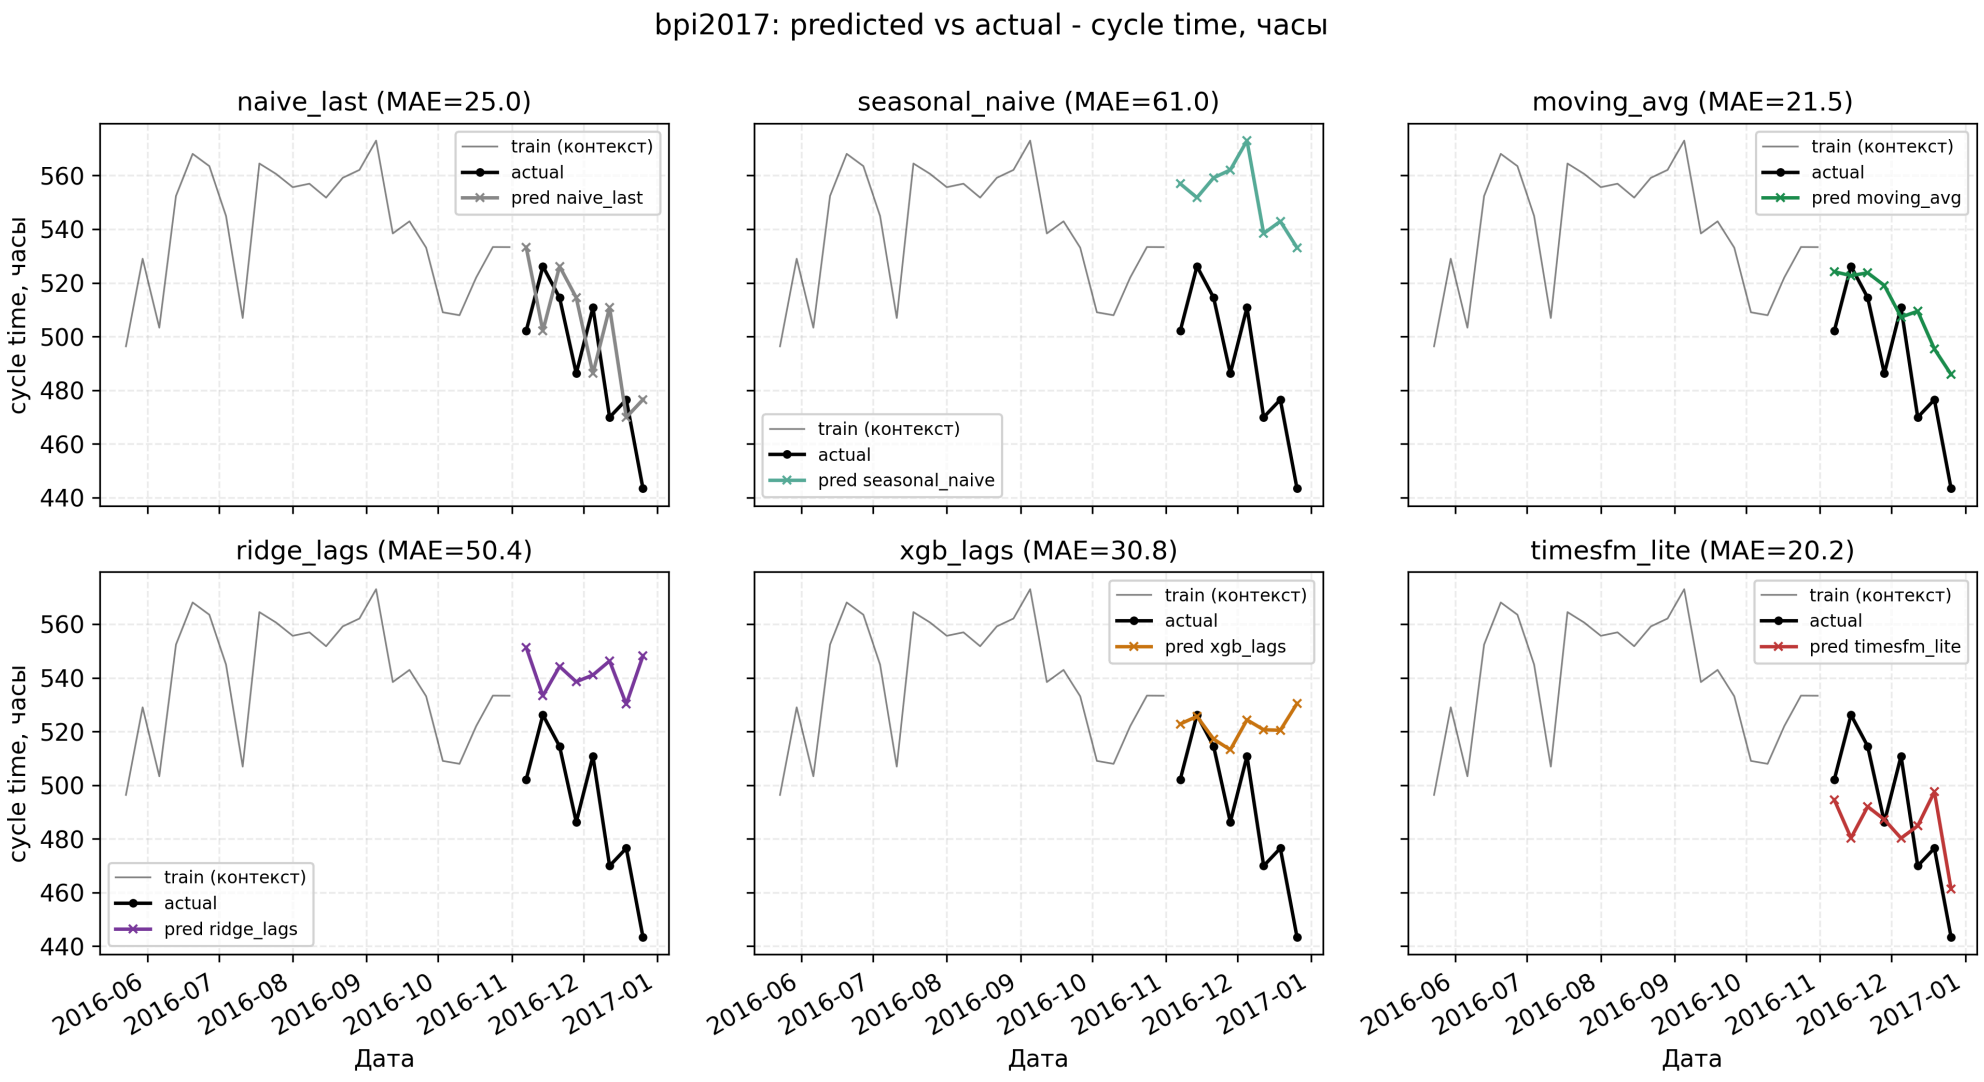

7. Результаты: 142_БЗ - честный негативный результат

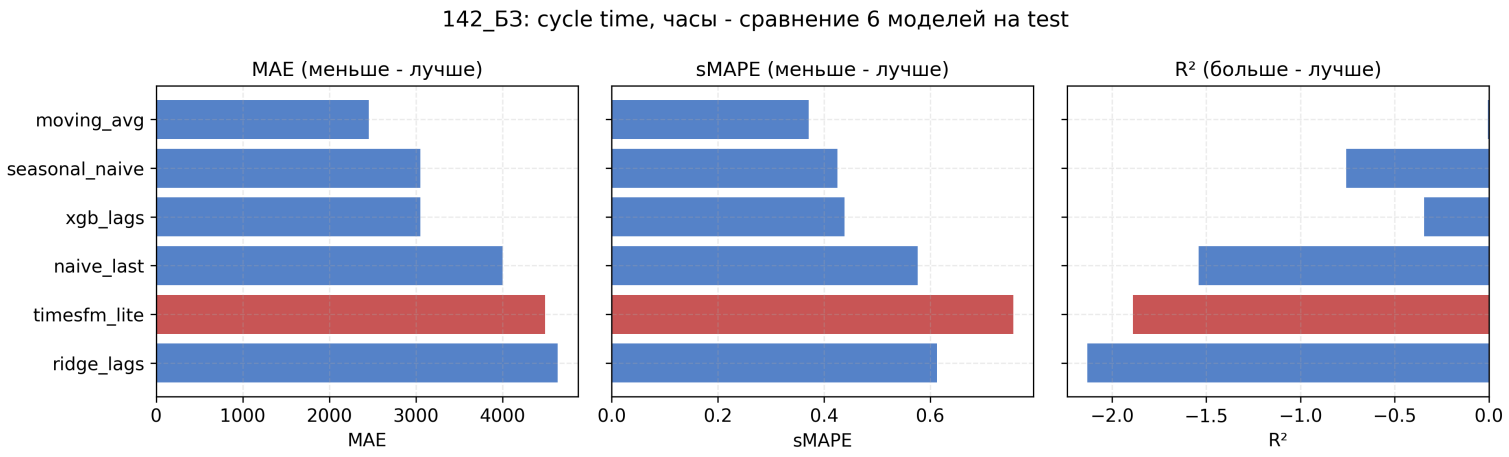

модель	MAE (ч)	sMAPE	R^2
moving_avg	**2 455**	**0.371**	-0.006
chronos zero-shot	3 414	0.499	-0.631
Transformer (наш)	4 491	0.756	-1.889

На сильно дрейфующем 142_БЗ **никакая ML не побила moving_avg**. Это не баг - это свойство данных: heavy tail + concept drift.

7. Разбор ошибок (residuals)

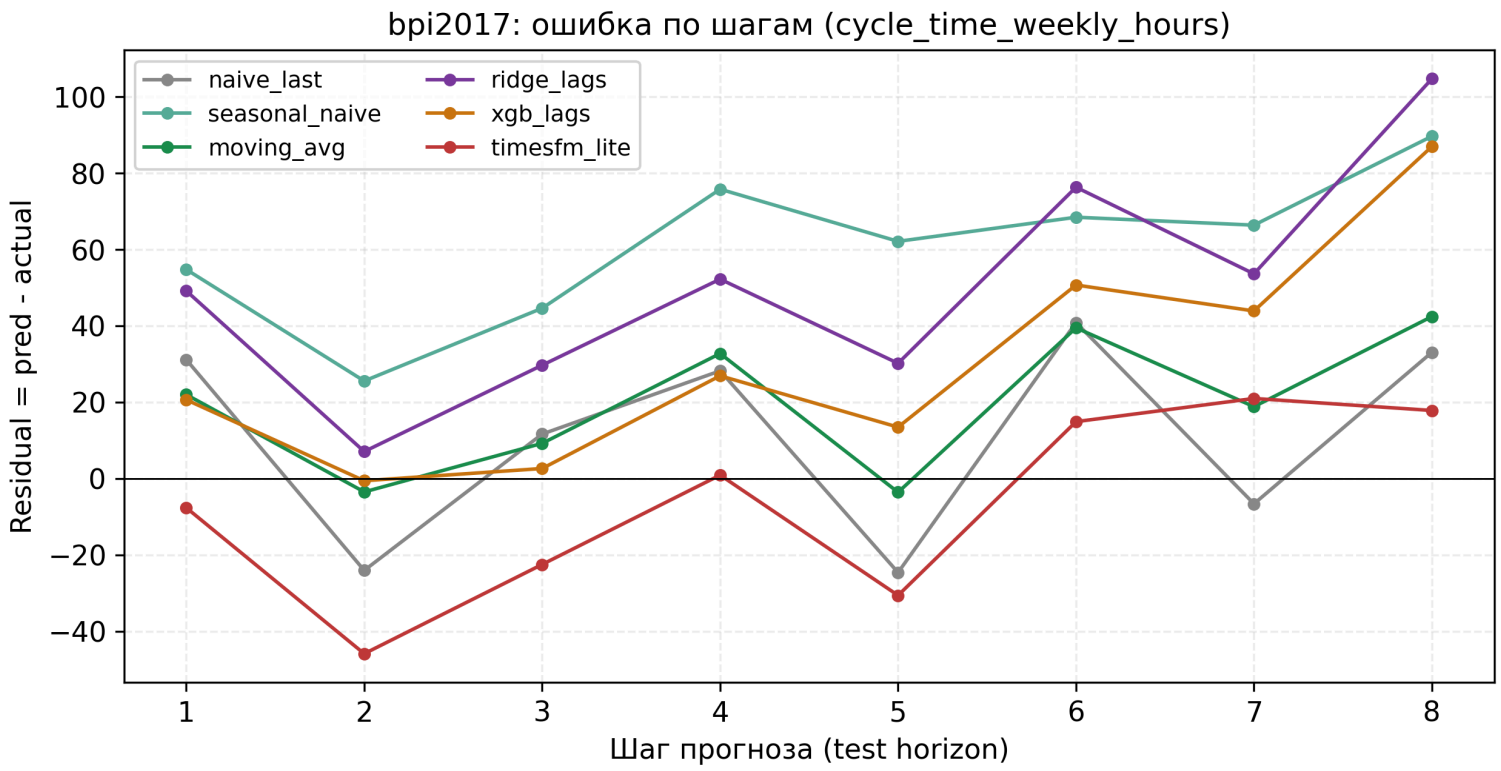

- naive_last: маленькие ошибки на стабильных, большие на скачках
- moving_avg: систематически отстаёт на трендах
- Transformer: residuals центрированы около 0, амплитуда меньше

8. Выводы

1. **Encoder-only Transformer обучен и работает**: на bpi2017 cycle_time
   - **лидер** по всем метрикам (MAE 20.16 vs moving_avg 21.49 vs Chronos 27.86).
2. **На коротких рядах (53 точки)** Transformer выигрывает, благодаря compact-архитектуре (72k params), delta-обучению и SmoothL1.
3. **На сильно дрейфующих рядах (142_БЗ)** простые методы выигрывают - это честный результат, согласующийся с природой задачи.
4. **Foundation Chronos** zero-shot не побеждает обученную модель на коротких бизнес-рядах. Pretraining не магия, нужна длинная серия.

Дальнейшие улучшения

- Daily-гранулярность (×7 длиннее) → foundation models должны выиграть
- Multi-step forecasting через teacher forcing
- Quantile regression / conformal prediction для интервалов
- External covariates (holidays, конец квартала, regulation changes)
- Online learning для адаптации под drift

Спасибо за внимание

Репозиторий: github.com/prodcent/ai-cos-coursework

Что внутри:

- 21 PNG-график (EDA, training, results)
- standalone `train_transformer.py` для воспроизведения
- 8 моделей в сравнении, JSON с метриками
- слайды и speech

Запуск Transformer:

```
KMP_DUPLICATE_LIB_OK=TRUE python src/train_transformer.py \
    --dataset bpi2017 --kpi cycle_time --epochs 80
```

Вопросы?